

BLM0463 — Veri Madenciliğine Giriş
Dönem Projesi Raporu

Karar Ağacı ile Çevrimiçi Derslerde Öğrenci Dikkat Düzeyi Tespiti

*Students Attention Detection Dataset
Hossen & Uddin (2023) — Data in Brief*

Öğrenci:	Büşra Ünal
Numara:	22360859084
Yöntem:	Decision Tree (Karar Ağacı)
Accuracy:	%99.88
F1-Score:	%99.85

github.com/bisraunal/decision-tree-student-attention

99.88

% Accuracy

1. Özet

Bu çalışmada, Hossen ve Uddin tarafından 2023 yılında *Data in Brief* dergisinde yayınlanan **Students Attention Detection Dataset** üzerinde Karar Ağacı (Decision Tree) sınıflandırma yöntemi uygulanmıştır. Veri seti, çevrimiçi derslere katılan öğrencilerin webcam görüntülerinden MediaPipe (yüz, el, baş duruşu) ve YOLOv7 (cep telefonu tespiti) kullanılarak çıkarılan 16 özelliği içermekte ve 4.000 örnekten oluşmaktadır.

Optimize edilmiş Karar Ağacı modeli test setinde **%99.88 doğruluk**, **%100 kesinlik (precision)**, **%99.70 duyarlılık (recall)** ve **%99.85 F1 skoru** elde etmiştir. 5-fold çapraz doğrulamada ortalama doğruluk **%99.90 ± %0.05** olarak ölçülmüştür. Aynı veri setinde Hossen ve Uddin (2023) tarafından XGBoost ile elde edilen **%99.75** doğruluğun **0.13 puan** üzerindedir.

Anahtar Kelimeler: Veri madenciliği, Karar ağacı, Sınıflandırma, Öğrenci dikkati, Çevrimiçi öğrenme, MediaPipe, YOLOv7, scikit-learn

2. Giriş

COVID-19 pandemisinin ardından çevrimiçi eğitim yaygın bir öğretim modeline dönüşmüştür. Ancak bu model, fiziksel sınıflarda öğretmenlerin doğal olarak yürüttüğü dikkat takibi konusunda ciddi zorluklar barındırmaktadır. Öğrencilerin kameralarının kapalı olması, dijital dikkat dağıtıcılar (telefon, başka sekmeler) ve göz teması kuramama gibi etkenler, eğitmenin öğrenci katılımını değerlendirmesini güçleştirmektedir. Bu nedenle bilgisayarlı görü ve makine öğrenmesi temelli otomatik dikkat tespit sistemleri artan bir araştırma alanı haline gelmiştir.

Bu projenin amacı, BLM0463 ders kapsamında **Karar Ağacı** yöntemini uygulayarak gerçek öğrenci verilerinden dikkat tespiti yapmak ve sonuçları yaygın değerlendirme ölçütleriyle (Accuracy, Precision, Recall, F1, Specificity, ROC-AUC) raporlamaktır. Ayrıca aynı veri seti üzerinde yapılmış akademik çalışmayla karşılaştırma sunulmaktadır.

2.1. Çalışmanın Katkıları

(i) Kapsamlı keşifsel veri analizi ve 14 farklı görselleştirme. **(ii)** Makaledeki ön işleme yaklaşımıyla tam uyumlu adımlar. **(iii)** 384 parametre kombinasyonu ile 5-fold GridSearchCV. **(iv)** Hossen ve Uddin (2023) XGBoost sonuçlarıyla karşılaştırma.

3. Veri Seti

Kullanılan **Students Attention Detection Dataset**, Hossen ve Uddin (2023) tarafından *Data in Brief* dergisinde yayınlanmış ve Mendeley Data üzerinden açık erişimli olarak paylaşılmıştır (DOI: 10.17632/smzggbnkd2.1). Veri seti, Bangladesh'teki Jahangirnagar Üniversitesi'nde Haziran 2023'te bilgisayar bilimleri dersine katılan öğrencilerden, webcam görüntülerinin 20 FPS hızıyla işlenmesiyle oluşturulmuştur.

3.1. Veri Toplama Mimarisi

Her video karesi dört modülden geçirilmiştir: **(1) Yüz tespiti** — MediaPipe BlazeFace; **(2) El takibi** — MediaPipe Hands; **(3) Baş duruşu tahmini** — MediaPipe Face Mesh + OpenCV solvePnP(); **(4) Cep telefonu tespiti** — YOLOv7 (MS-COCO ile eğitilmiş).


3.2. Özellikler ve Etiket

#	Özellik	Açıklama	Veri Tipi
1	no_of_face	Karedeki yüz sayısı	Tamsayı
2	face_x / face_y	Yüz kutu koordinatları	Float
3	face_w / face_h	Yüz genişlik ve yükseklik (px)	Float
4	face_con	Yüz tespit güven skoru	Float
5	no_of_hand	Algılanan el sayısı	Tamsayı
6	pose	Baş yönelimi (fwd/down/L/R)	Kategorik
7	pose_x / pose_y	Baş açıları (derece)	Float
8	phone	Telefon var mı? (0/1)	İkili
9	phone_x/y/w/h	Telefon koordinat ve boyutu	Float
10	phone_con	Telefon tespit güven skoru	Float
11	label	0 = Attentive, 1 = Inattentive	İkili

Tablo 1. Veri seti özellikleri ve veri tipleri.

3.3. Sınıf Dağılımı

Toplam **4.000 örnek**: **2.314 Attentive (%57.85)** ve **1.686 Inattentive (%42.15)**. Hafif dengesiz olsa da hiperparametre aramasında `class_weight='balanced'` seçeneği değerlendirilmiştir.



Şekil 1. Veri setindeki sınıf dağılımı.

3.4. Etiketleme Kriterleri


Modül	Attentive (0)	Inattentive (1)
Yüz	Yüz güvenle tespit edildi, merkezde	Yüz yok veya kısmen kadrada
El	Bir/iki el yüze yakın	El yok veya çok uzakta
Baş	İleri veya hafif eğik	Sol/sağ/aşağı yönelim
Telefon	Telefon yok veya ekranı aşağıda	Telefon ekranı yukarıda

Tablo 2. Deterministik etiketleme kuralları (Hossen & Uddin, 2023).


Önemli gözlem: Etiketler kural-tabanlı atandığı için özellik uzayından etiketlere büyük ölçüde deterministik bir eşleme bulunmaktadır. Bu durum, Karar Ağacı gibi kural çıkarımına dayalı modellerin neden çok yüksek doğruluk elde ettiğini açıklamaktadır (Bölüm 7'de detaylı tartışılmıştır).

3.5. Keşifsel Veri Analizi


Veri setinde eksik değer yoktur; 30 satır tekrardır (toplamın %0.75'i). Kategorik *pose* dağılımı: 2.951 forward, 537 down, 334 left, 178 right.




Şekil 2. Baş yönelimi dağılımı.




Şekil 3. Pose × sınıf çapraz dağılımı. 'forward' dışı büyük ölçüde Inattentive.




Şekil 4. Pearson korelasyon matrisi. Telefon özellikleri kendi aralarında >0.85 korelasyona sahiptir.



Şekil 5. Yüz koordinatları $\times$ dikkat sınıfı. İki sınıf büyük ölçüde örtüşmektedir.



Şekil 6. Yüz ve telefon tespiti güven skorları kutu grafiği.



Şekil 7. Anahtar özelliklerin sınıf bazında histogramları.

4. Yöntem

4.1. Karar Ağacı (Decision Tree)

Karar Ağacı, denetimli öğrenmede yaygın, ağaç yapısına dayalı ve yorumlanabilir bir sınıflandırma yöntemidir. Veri kümesini ardışık 'eğer-ise' koşullarıyla bölerek yapraklarda sınıf etiketi atar. Bu çalışmada scikit-learn'ün *DecisionTreeClassifier* sınıfı kullanılmıştır. Bölme kriteri olarak Gini indeksi ve Bilgi Kazancı (Entropi) değerlendirilmiştir.

Gini İndeksi: $Gini(t) = 1 - \sum p_i^2$ | **Entropi:** $H(t) = - \sum p_i \log_2(p_i)$

Avantajları: (i) yüksek yorumlanabilirlik, (ii) ölçeklemeye duyarsızlık, (iii) karma veri tipi desteği, (iv) hızlı eğitim. Dezavantajı: aşırı öğrenme eğilimi — *max_depth*, *min_samples_split* gibi parametrelerle düzenlenileştirilir.

4.2. Ön işleme

1. *pose* sütunu one-hot encoding ile 4 ikili sütuna dönüştürüldü. **2.** *face_con* [0,100] → [0,1] normalize edildi. **3.** Tüm özellikler **MaxAbsScaler** ile [-1,1] aralığına ölçeklendi. **4.** %80 eğitim (3.200) / %20 test (800) stratified split (random_state=42).

4.3. Hiperparametre Optimizasyonu

GridSearchCV ile **384** parametre kombinasyonu, **5-fold** çapraz doğrulama, **F1** hedef metriği ile optimize edildi (toplam 1.920 model uydurma).

Parametre	Aranan Değerler
criterion	gini, entropy
max_depth	None, 5, 10, 15, 20, 30
min_samples_split	2, 5, 10, 20
min_samples_leaf	1, 2, 5, 10
class_weight	None, balanced

Tablo 3. GridSearchCV parametre uzayı.

4.4. Değerlendirme Metrikleri

Accuracy = $(TP+TN) / (TP+TN+FP+FN)$ | **Precision** = $TP/(TP+FP)$ | **Recall** = $TP/(TP+FN)$ | **Specificity** = $TN/(TN+FP)$ | **F1** = $2 \cdot P \cdot R / (P+R)$ | **ROC-AUC**

5. Bulgular ve Sonuçlar

5.1. Baseline (Varsayılan Parametreler)

Metrik	Değer
Accuracy	%99.88
Precision	%100.00
Recall	%99.70
Specificity	%100.00
F1-Score	%99.85
ROC-AUC	0.9985

Tablo 4. Baseline test seti performansı.

5.2. Optimize Edilmiş Model


En iyi parametreler: **criterion=gini**, **max_depth=None**, **min_samples_split=20**, **min_samples_leaf=1**. 5-fold CV F1: **0.9978**.

Metrik	Değer
Accuracy	%99.88
Precision	%100.00
Recall	%99.70
Specificity	%100.00
F1-Score	%99.85
ROC-AUC	0.9985

Tablo 5. Optimize edilmiş modelin test seti performansı.


5.3. Confusion Matrix

800 test örneğinden yalnızca **1** tanesi yanlış sınıflandırılmıştır: TN=463, FP=0, FN=1, TP=336.




Şekil 8. Baseline ve tuned model Confusion Matrix karşılaştırması.

5.4. ROC ve Precision-Recall Eğrileri



Şekil 9. ROC eğrisi (AUC = 0.9985).



Şekil 10. Precision-Recall eğrisi.

5.5. 5-Fold Çapraz Doğrulama

Metrik	Ortalama $\pm$ Std	Min - Max
ACCURACY	0.9990 $\pm$ 0.0005	0.9988 - 1.0000
PRECISION	0.9994 $\pm$ 0.0012	0.9970 - 1.0000
RECALL	0.9982 $\pm$ 0.0015	0.9970 - 1.0000
F1	0.9988 $\pm$ 0.0006	0.9985 - 1.0000
ROC_AUC	0.9989 $\pm$ 0.0006	0.9985 - 1.0000


Tablo 6. 5-fold çapraz doğrulama sonuçları.

5.6. Özellik Önemleri

Sıra	Özellik	Önem Skoru
1	pose_forward	0.4921
2	phone_y	0.3169
3	pose_y	0.0993
4	pose_x	0.0665
5	face_con	0.0150

Tablo 7. En önemli 5 özellik.


pose_forward (0.49) — Öğrencinin başının ileriye dönük olup olmaması en güçlü belirleyici. **phone_y** (0.32) — Telefonun dikey konumu ikinci sırada. **pose_y** ve **pose_x** (toplam 0.17) — Açısal baş yönelimi. Bu sıralama etiketleme kurallarının dolaylı bir doğrulamasıdır.



Şekil 11. Tüm özelliklerin önem skorları.


5.7. Karar Ağacı Yapısı

Kök düğüm *pose_forward*: öğrencinin başı ileri dönük değilse ($\text{pose_forward} \leq 0.5$), 844 örneğin tamamı Inattentive olarak sınıflandırılmaktadır (Gini=0).



Şekil 12. Karar Ağacı (ilk 4 düzey).

5.8. Learning Curve




Şekil 13. Learning curve.

6. Akademik Çalışma ile Karşılaştırma

Referans çalışma: Hossen ve Uddin (2023), *Computers and Education: AI*, altı farklı ML algoritmasını karşılaştırarak **XGBoost ile %99.75 doğruluk** raporlamıştır. İkinci referans: Mello-Roman et al. (2023), benzer bir dikkat veri setinde XGBoost ile **%80.52** doğruluk elde etmiştir.

Çalışma	Yöntem	Veri Seti	Accuracy	Precision
Bu Çalışma (Baseline)	Decision Tree	Hossen 2023	%99.88	%100.00
Bu Çalışma (Tuned)	Decision Tree	Hossen 2023	%99.88	%100.00
Hossen & Uddin (2023)	XGBoost	Hossen 2023	%99.75	%99.71
Mello-Roman et al. (2023)	XGBoost	Kendi verisi	%80.52	—

Tablo 8. Literatür karşılaştırması. Sarı satır: bu çalışmanın tuned modeli.



Şekil 14. Doğruluk karşılaştırması.

6.1. Karşılaştırma Yorumu

Karar Ağacı, XGBoost'u **0.13 puan** geçmiştir. Bu, etiketlerin kural-tabanlı atanmış olmasından kaynaklanmaktadır — Karar Ağacı bu tür deterministik eşlemeleri doğal olarak öğrenir. Karar Ağacının avantajları: **(a)** her tahmin görsel olarak açıklanabilir, **(b)** eğitim ve tahmin çok hızlı, **(c)** model boyutu küçük, **(d)** gerçek zamanlı uygulamalar için ideal.

7. Tartışma ve Sınırlılıklar

%99.88 doğruluğu büyük ölçüde veri setinin yapısından kaynaklanmaktadır: etiketler deterministik kurallarla atanmış olduğundan, sınıflandırıcı bu kuralları yeniden

öğrenmektedir. Gerçek dikkat algılaması çok daha karmaşıktır.

Veri seti sınırlılıkları: (i) Aydınlatma/oda düzeni biasları, (ii) Tek üniversiteden örnekler, (iii) Sadece dış davranışlara dayalı etiketleme, (iv) Hafif sınıf dengesizliği.

Yöntemsel sınırlılıklar: (i) 30 yinelenen satır veri sızıntısına neden olabilir, (ii) Tek `random_state`, (iii) Sadece 1 yanlış sınıflandırma ile hata analizi sınırlı.

8. Sonuç

Karar Ağacı modeli test setinde **%99.88 doğruluk** ve **%99.85 F1** skoru elde etmiştir. Referans XGBoost çalışmasını 0.13 puan aşmıştır. 5-fold CV ($\%99.90 \pm \%0.05$) kararlılığı teyit etmiştir. `pose_forward` ve `phone_y` en belirleyici özelliklerdir.

Gelecek çalışmalar: (i) Random Forest/XGBoost ile doğrudan karşılaştırma, (ii) Farklı demografik veri setlerinde genelleme, (iii) SHAP ile açıklanabilir AI, (iv) Zamansal modelleme (LSTM).

9. Kaynaklar

- [1] Hossen, M. K., Uddin, M. S. (2023). A dataset for assessing real-time attention levels of the students during online classes. *Data in Brief*, 51, 109771.
- [2] Hossen, M. K., Uddin, M. S. (2023). Attention monitoring of students during online classes using XGBoost classifier. *Computers and Education: AI*, 5, 100191.
- [3] Hossen, M. K., Uddin, M. S. (2025). From data to insights: Using gradient boosting classifier to optimize student engagement in online classes with explainable AI. *Education and Information Technologies*, 30, 18089–18130.
- [4] Hossen, M. K., Uddin, M. S. (2023). Students Attention Detection Dataset, v1. *Mendeley Data*. DOI: 10.17632/smzggbnkd2.1
- [5] Mello-Roman, J. D., et al. (2023). Machine Learning applied to student attentiveness detection. *Education and Information Technologies*.
- [6] Pedregosa, F., et al. (2011). Scikit-learn: Machine learning in Python. *JMLR*, 12(85), 2825–2830.
- [7] Chen, T., Guestrin, C. (2016). XGBoost: A scalable tree boosting system. *KDD '16*, 785–794.
- [8] Lugaresi, C., et al. (2019). MediaPipe: A framework for perceiving and processing reality. *CV for AR/VR Workshop, IEEE CVPR*.
- [9] Wang, C. Y., et al. (2023). YOLOv7: Trainable bag-of-freebies. *IEEE/CVF CVPR*, 7464–7475.
- [10] Bradski, G. (2000). The OpenCV library. *Dr. Dobbs's Journal*, 25(11), 120–123.

EK A — Tekrar Üretilirlik

GitHub: <https://github.com/bisraunal/decision-tree-student-attention>

Tüm rastgele işlemlerde *random_state=42* sabitlenmiştir. Çalıştırma: `pip install -r requirements.txt && python src/main.py`